

FRASE 1: "El banco Aquático"

1) Para entender y calcular un bloque de un transformer lo primero que hay que hacer es construir la entrada $X = E + P$ que corresponde a sumar el embedding de cada palabra con el de su respectiva posición.
Fraser = [el, banco, aquático]

$$X_{[el]} = [0, 0, 0, 1] + [0, 0, 0, 0] = [0, 0, 0, 1]$$
$$X_{[banco]} = [1, 1, 1, 0] + [0, 0, 0, 1] = [1, 1, 1, 0]$$
$$X_{[aquático]} = [1, 0, 1, 0] + [0, 0, 0, 2] = [1, 0, 1, 2]$$
$$X = \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 1, 0 \\ 1, 0, 1, 2 \end{bmatrix}$$

2) Luego calculamos Q, K y V que corresponden: Q, que info lleva cada token, K, las claves que representan que info ofrece y V, la info que se mezcla/relaciona según la atención.

Las proyecciones se calculan como $Q = X \cdot W_Q$, $K = X \cdot W_K$ y $V = X \cdot W_V$

Como W_Q y W_K son **identidades** $\Rightarrow Q = X$ y $V = X$

Calculo K como $K = X \cdot W_K$

$$K = \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 1, 0 \\ 1, 0, 1, 2 \end{bmatrix} \times \begin{bmatrix} 1, 0, 0, 0 \\ 0, 1, 0, 0 \\ 1, 1, 0, 0 \\ 0, 0, 0, 0 \end{bmatrix} = \begin{bmatrix} 0, 0, 0, 0 \\ 1, 1, 0, 0 \\ 2, 1, 0, 0 \end{bmatrix}$$

3) Calculo las afinidades como $S = Q \cdot K^T$

Como $Q = X$, transpongo K y las multiplico obteniendo una matriz que permite interpretar la compatibilidad entre la "consulta" de un token (Q) y la clave de otro (K).

$$S = \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 1, 0 \\ 1, 0, 1, 2 \end{bmatrix} \begin{bmatrix} 0, 1, 2 \\ 0, 1, 1 \\ 0, 0, 0 \\ 0, 1, 2 \end{bmatrix} = \begin{bmatrix} 0, 0, 0 \\ 0, 2, 3 \\ 0, 1, 2 \end{bmatrix}$$

Nota: Cada fila representa "a quien estoy buscando", el 0 no es relevante en el contexto y queda en 0. Las columnas indican a que token miro, siendo el número cuanto mayor representa mayor afinidad/relación y viceversa.

4) Ahora, el escalar por $\sqrt{d}$, siendo d la dimensión 4.

$$\frac{S}{\sqrt{d}} = \begin{bmatrix} 0, 0, 0 \\ 0, 1, 15 \\ 0, 05, 1 \end{bmatrix}$$

Esto permite suavizar los valores para evitar escalares grandes y a su vez probabilidades demasiado extremas, lo interpreto como un regularizador.

5) Aplico la máscara causal, el ndeo explica que es para que el modelo no "prediga el futuro", ya que evita que palabras posteriores influyan en las anteriores.

$$S_{mask} = \begin{bmatrix} 0, -\infty, -\infty \\ 0, 1, -\infty \\ 0, 05, 1 \end{bmatrix}$$

6) Luego se aplica softmax por cada fila para convertir en probabilidades.

$$softmax_i = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

$$softmax('banco') = f_{softmax}(0, 1, -\infty) = \frac{[e^0, e^1, e^{-\infty}]}{1 + e + 0} = [0.186, 0.307, 0.506]$$

Calculamos lo mismo para cada fila y queda:

$$A = \begin{bmatrix} 1, 0, 0 \\ 0.186, 0.307, 0.506 \\ 0.027, 0.307, 0.506 \end{bmatrix} \rightarrow$$
 Transformamos las afinidades en pesos positivos que suman 1, que muestran cuanto aporta cada token.

7) Mezclamos los valores de atención A.V

$$A.V = \begin{bmatrix} 1, 0, 0 \\ 0.186, 0.307, 0.506 \\ 0.027, 0.307, 0.506 \end{bmatrix} \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 1, 0 \\ 1, 0, 1, 2 \end{bmatrix} = \begin{bmatrix} 0, 0, 0, 2 \\ 0.186, 0.307, 0.506, 0.506 \\ 0.027, 0.307, 0.506, 0.506 \end{bmatrix}$$

Nota: Inyectamos contexto de otros tokens.

8) Sumamos la conexión residual $Z = X + AV$

$$Z = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 0.186 & 0.307 & 0 & 2 \\ 0.027 & 0.307 & 0.506 & 0.506 \end{bmatrix}$$

Nota: se conserva la representación original del token y además se le agrega info de la atención.

9) Normalización, arranco con fila de "banco" como ejemplo:

$$\mu = \frac{x_1 + x_2 + \dots + x_n}{n} = 1.366$$
$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{n} = 0.634$$
$$N(x) = \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}$$

$$LN(Z_{banco}) = [0.459, 0.459, -1.715, 0.747]$$

$$N = \begin{bmatrix} -0.577, -0.577, -0.577, 1.732 \\ 0.459, 0.459, -1.715, 0.747 \\ 0.027, -1.242, -0.243, 1.504 \end{bmatrix}$$

Nota: Continuamos y escalamos cada representación, estableciendo sus valores.

$$LN_{banco} = \frac{x_i - 1.366}{0.796}$$

$$LN_d = \frac{x_i - 0.5}{0.866}$$

$$LN_{aquático} = \frac{x_i - 1.713}{1.143}$$

10) Feed-Forward, transformamos independientemente la representación de cada token.

FNN = ReLU(LN(Z).W₁).W₂

$$\begin{bmatrix} -0.577, -0.577, -0.577, 1.732 \\ 0.459, 0.459, -1.715, 0.747 \\ 0.027, -1.242, -0.243, 1.504 \end{bmatrix} \times \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

Nota: Aplicamos ReLU = max(0, x) $\rightarrow$ Como W₂ es identidad: FFN = $\begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$

W₁ cambia las características y ReLU introduce No-linealidad, convirtiendo solo positivos, W₂ proyecta nuevamente a la dimensión 4, en este es la identidad.

11) Segunda conexión Residual $H = Z + FFN$

$$H = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 0.186 & 0.307 & 0 & 2 \\ 0.027 & 0.307 & 0.506 & 0.506 \end{bmatrix}$$

Nota: se conserva la representación del FNN y suma las mismas características aprendidas.

12) Layer Normalization Final:

$$LN(H) = \begin{bmatrix} -0.577, -0.577, -0.577, 1.732 \\ 0.459, 0.459, -1.715, 0.747 \\ 0.027, -1.242, -0.243, 1.504 \end{bmatrix}$$

Nota: nuevamente continuamos y escalamos cada representación, estableciendo sus valores.

13) Predicción: usamos la última fila y la multiplicamos por W_{out}.

$$h = [0.743, -1.405, -0.472, 1.084]$$
$$Logits = h \cdot W_{out} = [0, 0, -0.472, -0.472, 1.585, -2.81]$$

Nota: W_{out} transforma la representación final en un "puntaje" final para cada palabra del vocabulario, softmax los convierte en probabilidades.

$$W_{out} = \begin{bmatrix} 0 & 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$$e^{Logits} = [1, 1, 0.624, 0.624, 4.33, 0.003]$$

$$\sum e^{Logits} = 8.488$$

$$P_{pred} = \frac{e^{Logits}}{\sum e^{Logits}} = [0.122, 0.122, 0.074, 0.074, 0.506, 0.003]$$

Nota: El valor con probabilidad mayor es "pus" con 0.506 de probabilidad lo cual tiene sentido en el contexto de banco para natar.

FRASE 2: "El banco presta"

1) Como cambia la ultima palabra, reutilizo las filas "el" y "banco".
 $X_{[prsta]} = [0, 1, 1, 0] + [0, 0, 0, 2] = [0, 1, 1, 2]$ $X' = \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 0, 1 \\ 0, 1, 1, 2 \end{bmatrix}$

2) Calculo K' como $K' = X' \cdot W_k$

$$K' = \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 0, 1 \\ 0, 1, 1, 2 \end{bmatrix} \times \begin{bmatrix} 1, 0, 0, 0 \\ 0, 1, 0, 0 \\ 1, 1, 0, 0 \\ 0, 0, 0, 0 \end{bmatrix} = \begin{bmatrix} 0, 0, 0, 0 \\ 1, 1, 0, 0 \\ 1, 2, 0, 0 \end{bmatrix} \begin{matrix} K_{[el]} \\ K_{[banco]} \\ K_{[prsta]} \end{matrix}$$

3) Calculo las afinidades como $S' = Q \cdot K'^T$
Como $Q = X'$, transformo K' y los multiplico

$$S' = \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 0, 1 \\ 0, 1, 1, 2 \end{bmatrix} \begin{bmatrix} 0, 1, 1 \\ 0, 1, 2 \\ 0, 0, 0 \\ 0, 0, 0 \end{bmatrix} = \begin{bmatrix} 0, 0, 0 \\ 0, 2, 3 \\ 0, 1, 2 \end{bmatrix}$$

4) Como $S = S' \rightarrow$ los pesos 4, 5 y 6 son iguales a la anterior frase.

$$A' = \begin{bmatrix} 1, 0, 0 \\ 0, 0, 0, 0 \\ 0, 0, 0, 0, 0 \end{bmatrix}$$

7) $AV' = \begin{bmatrix} 1, 0, 0 \\ 0, 0, 0, 0 \\ 0, 0, 0, 0, 0 \end{bmatrix} \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 0, 1 \\ 0, 1, 1, 2 \end{bmatrix} = \begin{bmatrix} 0, 0, 0, 1 \\ 0, 0, 0, 1 \\ 0, 0, 0, 1, 0, 1 \end{bmatrix}$

8) $Z' = X' + AV' = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 1, 1, 1 & 1, 1 & 1 & 1 \\ 0, 1, 0, 2 & 1, 0, 1 & 1, 0, 2 & 1, 0, 1 \end{bmatrix}$

9) $\mu = 1,783 \times \sigma = 1,443$
 $N(Z') = \begin{bmatrix} -0,577, -0,577, -0,577, 1,732 \\ 0,459, 0,459, -1,715, 0,797 \\ -1,292, 0,026, -0,292, 1,507 \end{bmatrix}$

10) FNN=ReLU(LN(Z'), W_h), U_h Como W_h es identidad:
 $\begin{bmatrix} -0,577, -0,577, -0,577, 1,732 \\ 0,459, 0,459, -1,715, 0,797 \\ -1,292, 0,026, -0,292, 1,507 \end{bmatrix} \times \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1,98 & 0 & 0 \end{bmatrix} \rightarrow \text{Aplicamos ReLU} = \max(0, z) \rightarrow \text{FFN} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1,98 & 0 & 0 \end{bmatrix}$

11) Segunda conexión Residual H=Z+FFN

$$H = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 1, 1, 1 & 1, 1 & 1 & 1 \\ 0, 1, 0, 2 & 1, 0, 1 & 1, 0, 2 & 1, 0, 1 \end{bmatrix} \rightarrow \text{convertir la representación del FNN y suma las mismas características aprendidas.}$$

12) Layer Normalization Final:

$$\mu = 2,113 \quad \sigma^2 = 1,652 \quad \sigma = 1,285 \quad LN(H) = \begin{bmatrix} -0,577, -0,577, -0,577, 1,732 \\ 0,459, 0,459, -1,715, 0,797 \\ -1,406, 0,293, -0,492, 1,084 \end{bmatrix}$$

13) Predicción: usamos la última fila y la multiplicamos por W_{out}.

$$h = [-1,406, 0,293, -0,492, 1,084] \quad \logits = h \cdot W_{out} = [0, 0, -0,472, -0,472, -2,810, 1,936] \rightarrow W_{out} \text{ transforma la representación final en un "punteo" final para cada palabra del vocabulario, softmax los convierte en probabilidades.}$$

Alora calculamos las representaci^ones:
 $e^{logits} = [1, 1, 0, 0, 0, 0]$
 $\sum e^{logits} = 9,488$
El calculo de softmax $\rightarrow \frac{e^{logits}}{\sum e^{logits}} = [0,122, 0,122, 0,076, 0,076, 0,003, 0,890]$
El valor con probabilidad mayor es "banco" con 0,890 de probabilidad lo cual tiene sentido en el contexto de bancos de finanzas. Sabemos que es "banco" porque su indice corresponde al de su respectiva columna en W_{out}

PARTE B Sin Mascara

5) Igual en ambas cases:

$$\frac{S}{Jd} = \begin{bmatrix} 0, 0, 0 \\ 0, 1, 1, 5 \\ 0, 0, 5, 1 \end{bmatrix} \xrightarrow{\text{sin mascara}} \begin{bmatrix} 0, 0, 0 \\ 0, 1, 1, 5 \\ 0, 0, 5, 1 \end{bmatrix} \rightarrow \text{Cada token puede utilizar el contexto completo, incluyendo tokens posteriores.}$$

6) Aplico softmax:

$$\begin{bmatrix} 0, 0, 0 \\ 0, 1, 1, 5 \\ 0, 0, 5, 1 \end{bmatrix} \xrightarrow{\text{softmax}} \begin{bmatrix} 0,333 & 0,333 & 0,333 \\ 0,422 & 0,331 & 0,594 \\ 0,186 & 0,307 & 0,506 \end{bmatrix}$$

7) Frase "El banco aguenta" $AV = \begin{bmatrix} 0,333 & 0,333 & 0,333 \\ 0,422 & 0,331 & 0,594 \\ 0,186 & 0,307 & 0,506 \end{bmatrix} \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 0, 1 \\ 1, 0, 1, 2 \end{bmatrix} = \begin{bmatrix} 0,467 & 0,333 & 0,333 & 1,333 \\ 0,896 & 0,331 & 0,594 & 1,594 \\ 0,819 & 0,307 & 0,506 & 1,506 \end{bmatrix} \rightarrow \text{sin la máscara la palabra "banco" incorpora la información de "aguenta".}$ 8) $Z = X + AV$ $Z = \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 0, 1 \\ 1, 0, 1, 2 \end{bmatrix} + \begin{bmatrix} 0,467 & 0,333 & 0,333 & 1,333 \\ 0,896 & 0,331 & 0,594 & 1,594 \\ 0,819 & 0,307 & 0,506 & 1,506 \end{bmatrix} = \begin{bmatrix} 0,467 & 0,333 & 0,333 & 2,333 \\ 1,896 & 1,331 & 0,594 & 2,594 \\ 1,819 & 0,307 & 0,506 & 3,006 \end{bmatrix}$ 9) $LN_{banco} = \frac{x_i - 1,576}{0,734}$ $LN_d = \frac{x_i - 0,949}{0,829}$ $LN_{aguenta} = \frac{x_i - 1,783}{1,443}$ $N = \begin{bmatrix} -0,302 & -0,704 & -0,704 & 1,704 \\ 0,442 & -0,333 & -1,403 & 1,323 \\ 0,026 & -1,292 & -0,292 & 1,507 \end{bmatrix}$	7) Frase "El banco presta" $AV = \begin{bmatrix} 0,333 & 0,333 & 0,333 \\ 0,422 & 0,331 & 0,594 \\ 0,186 & 0,307 & 0,506 \end{bmatrix} \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 0, 1 \\ 0, 1, 1, 2 \end{bmatrix} = \begin{bmatrix} 0,333 & 0,467 & 0,333 & 1,333 \\ 0,331 & 0,896 & 0,594 & 1,594 \\ 0,307 & 0,819 & 0,506 & 1,506 \end{bmatrix} \rightarrow \text{sin la máscara la palabra "banco" incorpora la información de "presta".}$ 8) $Z = X + AV$ $Z = \begin{bmatrix} 0, 0, 0, 1 \\ 1, 1, 0, 1 \\ 1, 0, 1, 2 \end{bmatrix} + \begin{bmatrix} 0,333 & 0,467 & 0,333 & 1,333 \\ 0,331 & 0,896 & 0,594 & 1,594 \\ 0,307 & 0,819 & 0,506 & 1,506 \end{bmatrix} = \begin{bmatrix} 0,333 & 0,467 & 0,333 & 2,333 \\ 1,331 & 1,896 & 0,594 & 2,594 \\ 1,307 & 0,819 & 1,006 & 3,006 \end{bmatrix}$ 9) $LN_{banco} = \frac{x_i - 1,576}{0,734}$ $LN_d = \frac{x_i - 0,949}{0,829}$ $LN_{presta} = \frac{x_i - 1,783}{1,443}$ $N = \begin{bmatrix} -0,704 & -0,302 & -0,704 & 1,704 \\ -0,333 & 0,442 & -1,403 & 1,323 \\ -1,292 & 0,026 & -0,292 & 1,507 \end{bmatrix}$
--	---

"El banco presta" = [-1,292 0,026 -0,292 1,507] sin máscara la palabra "banco" tiene contexto de la siguiente palabra.
↳ con "aguenta" aumenta relativamente la dimensión asociada a tokens finicos.
"El banco aguenta" = [0,026, 1,292, -0,292, 1,507] ↳ con "presta" aumenta relativamente la dimensión asociada a el dinero.

Por esto el encoder produce dos representaciones diferentes para la misma palabra.

PRE CUNTAS.

- 1) En la parte A son iguales y en la B diferentes, esto se debe a que en la última al no tener la máscara, la palabra "banco" cuenta con el contexto de la siguiente palabra que es $\neq$ en cada caso.
- 2) La predicción se hace sobre el vector de la última posición, no el de "banco", sino que el de "pronta" y "aguantá" en cada caso, lo cual activa distintos dimensiones asociadas a "pero" o "dinero".
- 3) Son iguales para la última posición, la máscara solo está incluír tokens posteriores y como después del último no hay nada, tiene el mismo contexto (toda la frase).
- 4) La parte A se parece a un decoder como GPT que se usa para predecir el siguiente token y generar texto.
La parte B se parece a un encoder como BERT que se usa para comprender y representar texto.
Si P fuera token O cambiarían X , las normalizaciones y probabilidades, aunque se conservaría la diferencia entre pero y dinero. Si se cambia el orden, el modelo pierde información crucial ya que no puede ubicar cada palabra lo que puede generar distintos significados.
- 5) Si P fuera token O, cambiarían X , las normalizaciones y probabilidades, aunque se conservaría la diferencia entre pero y dinero.